2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 28

Santamarina, Alejo

Lombardi, Viggo

Centurion, Nicolas

1. Introducción

En este trabajo analizamos los datos de la Encuesta Nacional de Factores de Riesgo (ENFR)[1] realizada por el INDEC en 2018 junto con el Ministerio de Salud y Desarrollo Social de la Nación. La base de datos contiene 29.224 registros y 287 variables, correspondientes a personas de 18 años o más que residen en localidades de 5.000 habitantes o más. Una particularidad de esta edición es que, además de las respuestas declaradas por los encuestados, se incorporaron mediciones físicas y bioquímicas, como la presión arterial, el peso, la glucemia y el colesterol.

Primero exploramos las características de la base e investigamos posibles problemas en los datos. Después seleccionamos las variables de interés y planteamos tres hipótesis propias, además de las tres propuestas por la cátedra, que evaluamos mediante pruebas estadísticas.

Para empezar a trabajar sobre los datos vimos el manual de uso de la base de datos brindado por INDEC[2] , donde se explica qué representa cada variable y cómo se codifican las respuestas. La principal dificultad inicial fue organizar las 287 variables para poder analizarlas.

2. Análisis exploratorio de los datos

Con la información de cada variable las clasificamos en temáticas para facilitar el análisis de las 287 variables diferentes:

Conjunto / Grupo	Descripción	Variables
1. Dominios de Estimación e Información Muestral	Variables de identificación geográfica, diseño muestral y selección de submuestras.	id, cod_provincia, region, tamanio_aglomerado, aglomerado, localidades_150, submuestra
2. Bloque Hogar (BH)	Características de la vivienda, composición del hogar, ingresos y situación sociodemográfica y laboral del jefe/a de hogar.	
↳ Características de la vivienda (CV)	Condiciones y características físicas de la vivienda.	bhcv01, bhcv02, bhcv03, bhcv04, bhcv05, bhcv06, bhcv07, bhcv08, bhcv09, bhcv10, bhcv11
↳ Características del hogar (HO)	Composición, cantidad de integrantes y tipo de hogar.	bhho01, bhho02, bhho03, cant_componentes, miembros_18, tipo_hogar
↳ Ingresos del hogar (IH)	Ingresos familiares, rangos económicos e imputaciones.	bhih01, bhih01_02, rango_ingreso, quintil_uc, imputado, bhih03
↳ Características de la jefatura del hogar (CH - Jefe/a)	Características sociodemográficas, educación y cobertura de salud del jefe/a del hogar.	bhch03_j, bhch04_j, rango_edad_j, bhch05_j, nivel_instruccion_j, nivel_instruccion_agrupado_j, bhch10_01_j, bhch10_02_j, bhch10_03_j, bhch10_04_j, bhch10_05_j, bhch10_06_j, bhch10_99_j, cobertura_salud_j
↳ Situación laboral del jefe/a de hogar (SL)	Situación ocupacional y condición de actividad del jefe/a.	bhsl01, bhsl02, bhsl03, bhsl04, bhsl05, bhsl06, condicion_actividad_j

3. Bloque Individual (BI) - Características del Respondente	Variables sociodemográficas de la persona sorteada para responder la encuesta.	
↳ Características sociodemográficas (CH - Seleccionado)	Sexo, edad, nivel educativo y cobertura de salud del respondente.	bhch02, bhch03, bhch04, rango_edad, bhch05, nivel_instruccion, nivel_instruccion_agrupado, bhch10_01, bhch10_02, bhch10_03, bhch10_04, bhch10_05, bhch10_06, bhch10_99, cobertura_salud
4. Bloque Individual (BI) - Paso 1 (Autorreporte)	Variables sobre condiciones de salud, hábitos, comportamientos y factores de riesgo informados por el encuestado.	
↳ Situación laboral personal (SL)	Situación ocupacional y condición de actividad del respondente.	bisl01, bisl02, bisl03, bisl04, bisl05, bisl06, condicion_actividad
↳ Salud general (SG)	Percepción del estado de salud y condiciones generales de bienestar.	bisg01, bisg02, bisg03, bisg04, bisg05, bisg06
↳ Actividad física (AF)	Frecuencia, duración, intensidad y barreras para realizar actividad física.	biaf01, biaf02_m, biaf02_99, biaf03, biaf04_m, biaf04_99, biaf05, biaf06_m, biaf06_99, biaf07_m, biaf07_99, biaf08, biaf09, biaf10_01, biaf10_02, biaf10_03, biaf10_04, nivel_actividad_fisica, barreras_actividad_fisica
↳ Tabaco (TA)	Consumo de tabaco, exposición al humo, intentos de abandono y percepción del riesgo.	bita01, bita02, bita02_99, bita03, bita04, bita04_01, bita04_02, bita05, bita06_a, bita06_b, bita06_b_99, bita06_c, bita06_d, bita07, bita07_99, bita08, bita09_01, bita09_02, bita09_03, bita09_04, bita09_05, bita09_06, bita10_01, bita10_02, bita10_03, bita10_04, bita10_05, bita10_06, bita11, bita12, bita13, bita14, bita15, bita16, consumo_tabaco_100, ta_paquete_y_armado, ta_dejar_fumar,

		ta_otros_productos, hta_nofumadores, ta_perc_publicidad, ta_percepcion_riesgo, imagenes_tabaco
↳ Hipertensión arterial (HA)	Antecedentes, diagnóstico, tratamiento y controles de hipertensión arterial.	biha01, biha02, biha03, biha04, biha05_01, biha05_02, biha06, biha06_99, biha07, biha08, biha09, biha10, biha11, biha11_99, biha12, biha13, biha14, biha15, control_hipertension, prevalencia_hipertension
↳ Peso corporal (PC)	Peso, talla e índice de masa corporal declarados por el encuestado.	bipc01, bipc02, bipc03, bipc04, bipc04_99, bipc05, bipc05_99, imc, imc_categorias
↳ Alimentación (AL)	Hábitos alimentarios, consumo de frutas y verduras y barreras alimentarias.	bial01, bial02, bial03, bial03_99, bial04, bial04_99, bial05, bial05_99, bial06, bial06_99, bial07, bial08, bial09, bial10, promedio_fv_diario, consumo_fv, barreras_fyv, tipo_dieta_razones
↳ Colesterol (CO)	Antecedentes, diagnóstico, tratamiento y controles del colesterol.	bico01, bico02, bico03, bico04, bico05_01, bico05_02, control_colesterol, prevalencia_colesterol
↳ Consumo de alcohol (CA)	Frecuencia, cantidad y patrones de consumo de bebidas alcohólicas.	bica01, bica02, bica03_01, bica03_02, bica03_99, bica04_01_b, bica04_01_c, bica04_02_b, bica04_02_c, bica04_03_b, bica04_03_c, bica04_04, bica05_01_b, bica05_01_c, bica05_02_b, bica05_02_c, bica05_03_b, bica05_03_c, bica05_04, bica06, bica07, consumo_regular_riesgo, consumo_episodico_excesivo
↳ Diabetes (DI)	Diagnóstico, antecedentes, tratamiento y controles de diabetes.	bidi01, bidi02, bidi03, bidi04_01, bidi04_02, bidi04_03, bidi05, bidi06_01, bidi06_02, bidi07, bidi08, bidi09, bidi10, bidi11, bidi12, bidi13, bidi14, control_diabetes, prevalencia_diabetes
↳ Lesiones viales (LE)	Antecedentes y factores relacionados con lesiones de tránsito.	bile01, bile02, bile03

↳ Prácticas preventivas (PP)	Realización de controles preventivos y estudios de detección de cáncer.	bipp01, bipp02, bipp03, bipp04, control_mamografia, control_pap
↳ Prevención de cáncer colorrectal (CC)	Prácticas de detección y controles preventivos de cáncer colorrectal.	bicc01_01, bicc01_02, bicc01_03, bicc02, bicc03, control_colon
5. Bloque Individual (BI) - Paso 2 (Mediciones Antropométricas - MA)	Variables obtenidas mediante el chequeo físico realizado en el domicilio: presión arterial, peso, talla, cintura e indicadores derivados.	bima01, bima02, bima03, bima04_01_a, bima04_01_b, bima04_02_a, bima04_02_b, bima04_03_a, bima04_03_b, promedio_sistolica, promedio_diastolica, ta_elevada, prevalencia_hipertension_combinada, bima06, bima07, bima09, bima10, imc_bima, imc_categorias_bima, bima12, bima13, bima14
6. Bloque Individual (BI) - Paso 3 (Mediciones Bioquímicas - MQ)	Variables obtenidas mediante mediciones bioquímicas capilares de glucemia y colesterol, junto con indicadores y puntajes de riesgo como FINDRISC.	bimq01, bimq05, bimq05_01, glucemia_elevada, prevalencia_glucemia_elevada_combinada, findrisc, bimq06, bimq06_01, colesterol_elevado, prevalencia_colesterol_combinada
7. Factores de Expansión	Ponderadores muestrales utilizados para proyectar los resultados a la población según el paso de la encuesta.	wf1p, wf2p, wf3p

Fig. 1: conjunto de variables organizadas en diferentes categorias.

Dentro del manual se mencionan cuales son los valores que representan cada respuesta para las variables. Se puede ver que en muchos casos el valor 99, 9 o 98 representa una opción de incertidumbre en la respuesta, es decir puede ser que no conocía la respuesta, no era aplicable, salto el cuestionario o similar, por eso los consideramos como valores inválidos y en la sección 1.3 realizamos este filtrado teniendo en consideración que en variables del tipo cuantitativas

pueden existir estos valores y ser correctos. Para el caso particular del valor 98 puede significar diferentes cosas dependiendo de la variable:

Variables	Significado documentado del 98
bita06_a	Fuma cigarrillos sueltos
bita10_01 a bita10_06	No estuvo en el lugar
bita11	No fue a comercios que venden cigarrillos
bita14	No vio paquetes de cigarrillos
bica06	No manejó en los últimos 30 días
bile01, bile02, bile03	No viaja en ese medio de transporte

Y se mantienen los datos originales por si se tiene que hacer un análisis futuro donde la distinción entre estos tenga sentido.

- Hay dos casos en los cuales el valor 9 representa Ns/Nc según el manual de uso: **bidi07** y **bhcv05**. Pero esta última al momento de ver el resumen de la variable se veía que en realidad usa el valor 99 y no 9.

Hay que considerar las variables que finalizan con _99, las cuales funcionan como “flags” para otras variables cuando el valor no se conoce el valor cuando el tipo de variable es cuantitativa, si a esas las ponemos como null va a tener ratios de 100% de null y vamos a perder información. Para eso hay que transformarlas en booleanas para poder manipularlas correctamente, al valor 99 lo pusimos como true mientras que al vacío lo consideramos como false.

- La variable bhch10_99_j particularmente en el manual figura como todas que el valor 99 es el valor que significa nuestro true pero en este caso en particular los valores que hay en el dataset son 1.0 para representar cuando el voluntario no conoce la respuesta.

En la sección 1.4.1 empezamos con un análisis muy superficial de todas las variables (separando las cuantitativas para mostrar , inicialmente habíamos hecho un código para mostrar todas las variables pero con las herramientas de pandas aplicadas sobre el dataset completo no mostraban toda la información o la resumía, así que usamos inteligencia artificial para mostrar esta información en un formato más limpio mediante iteraciones entre las categorías de variables establecidas en el cuadro de encima.

Realizamos una exploración inicial de las 287 variables, organizadas en los 23 conjuntos definidos anteriormente. Para cada variable mostramos información sobre su tipo de dato, valores nulos, valores únicos y medidas descriptivas según corresponda. Esto nos permitió identificar algunas particularidades, principalmente variables con grandes cantidades de nulos, valores extremos y diferencias importantes entre sus distribuciones. Primero lo que más nos llamó la atención fue el apartado de factores de expansión:

	Variable	dtype	Nulos	% nulos	Únicos	Resumen	Mín	Mediana	Media	Máx
0	wf1p	int64	0	0.0	4175		24.0	468.0	954.59	23922.0
1	wf2p	int64	0	0.0	4544		0.0	226.0	954.59	41470.0
2	wf3p	int64	0	0.0	3466		0.0	0.0	673.48	54990.0

Fig. 2: fragmento de output de sección 1.4.1 donde se define el tipo de variable y se muestra información relevante.

Estos son pesos estadísticos, y son valores puestos a propósito y calculados por el INDEC al finalizar el relevamiento. Estos se usan para poder tener un dataset menos sesgado y que representen mejor a toda la Argentina. Los valores que contienen estas variables representan a cuántas personas reales equivale esa única fila. En el mismo pie de página deja un link al documento metodológico[3] que explica cómo se definen estos valores:

- Compensación por falta de respuesta: Los factores de expansión incluyen ajustes para compensar la falta de respuesta de parte de las personas seleccionadas, buscando mantener la representatividad de la muestra.
- Probabilidad de selección: No todas las viviendas tienen la misma probabilidad de ser seleccionadas. Los factores de expansión tienen en cuenta estas diferencias para realizar estimaciones sobre la población.

Las tres etapas definidas son tres pasos de relevamiento, es hasta accedió el encuestado a dar información:

1. La variable wf1p es la entrevista verbal (preguntas sobre tabaco, alimentación, actividad física, etc.). Se le hizo al 100% de las viviendas seleccionadas en todas las regiones del país.

2. La variable wf2p es la toma de presión arterial, peso, talla y cintura con instrumental. El diseño de la encuesta redujo la muestra de viviendas para esta etapa. Como la muestra es más chica, los factores de expansión se recalculan para que esa submuestra siga representando al total del país.

3. La variable wf3p es la extracción de sangre (glucemia y colesterol). Es un recorte aún más drástico: solo se le hizo a las personas del Paso 2 que además viven en localidades de 150.000 habitantes o más.

Esto explica porque por ejemplo el máximo de wf3p es más del doble que el máximo de wf1p. Eliminar estas variables o no tenerlas en consideración al momento de realizar análisis es un error.

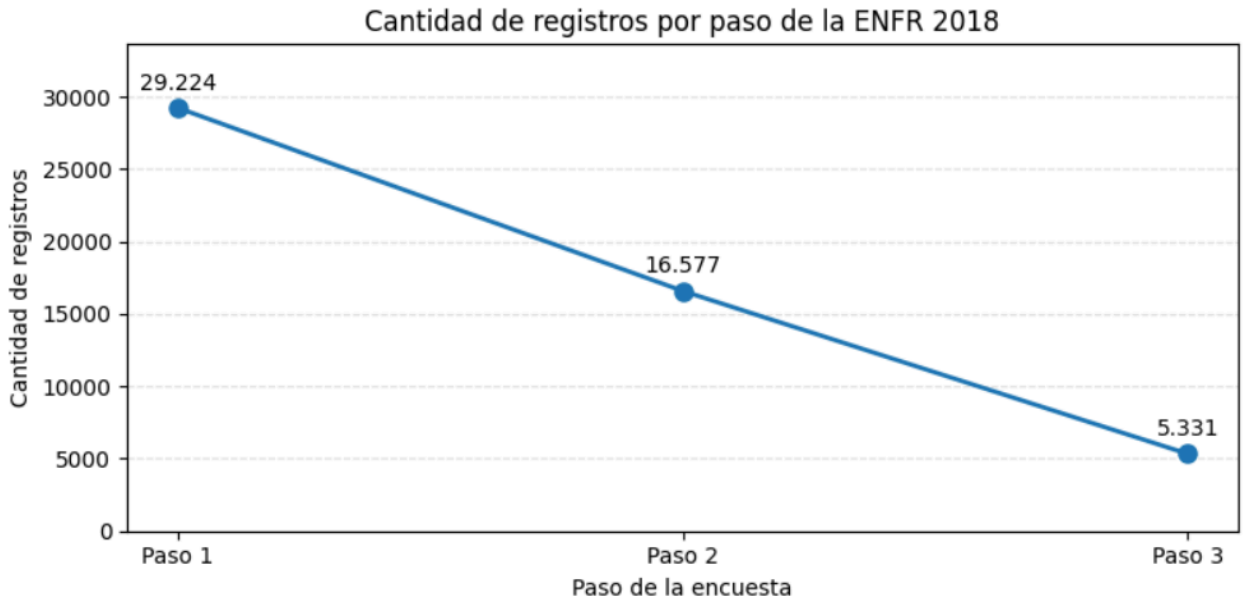


Fig. 3: Gráfico de la sección 2.3.1 comparando el tamaño muestral de cada etapa.

El mismo documento establece una regla metodológica fundamental para el análisis de datos: si requerís analizar en conjunto variables de dos pasos distintos de la encuesta, siempre debés usar el factor de expansión correspondiente al paso de menor desagregación o tamaño de muestra (por ejemplo, si cruzás variables del Paso 2 y 3, se tiene que usar wf3p). Esto lo vamos a tener en consideración al momento de tratar con hipótesis, ahora solo estamos trabajando con la cantidad real de los registros.

Respecto a los valores nulos (vacíos o NaN), las variables con alto porcentaje de estos (>70%) se pueden justificar por el funcionamiento de la encuesta realizada. Los espacios en blanco son puestos como valores en variables las cuales no corresponden a la persona en particular, casos como:

- **bita06_d** (Tipo de cápsula) con 96,35 % de nulos: Solo se responde si la persona fuma actualmente cigarrillos de paquete saborizados. Por eso, la mayoría de los encuestados no tiene un valor en esta variable.
- **biha11** (Pastillas no tomadas) con 99,21 % de nulos: Solo corresponde a personas diagnosticadas con hipertensión que toman medicamentos y declararon no haber tomado alguna de las pastillas indicadas durante la última semana.
- **bisl03** (Motivo de ausencia laboral) con 99,21 % de nulos: Solo se pregunta a quienes tienen trabajo, pero no asistieron durante la semana anterior.
- **promedio_sistolica** (Presión arterial) con ~45 % de nulos: No todos los encuestados participaron en la etapa de mediciones físicas. Además, algunas personas rechazan que se les tome la presión.
- **bimq05** (Glucemia) con ~82 % de nulos: La medición se realizó únicamente en una submuestra de personas de localidades de 150.000 habitantes o más. También requería el consentimiento para la extracción de una muestra de sangre, por lo que muchos registros quedaron vacíos.

Vimos que muchos de los valores nulos no son errores, sino que se deben al funcionamiento de la encuesta. Por ejemplo, hay preguntas que solamente corresponden a determinados encuestados y mediciones que se realizaron sobre submuestras. Por eso no tendría sentido eliminar todos los registros con valores nulos sin distinguir primero su origen.

Investigación de particularidades encontradas en el análisis exploratorio

Del resumen general de las 287 variables seleccionamos cinco que nos llamaron la atención por sus valores extremos, la cantidad de respuestas disponibles o posibles inconsistencias. Las analizamos por separado para entender mejor sus distribuciones.

En esta etapa trabajamos con los registros de la muestra sin aplicar factores de expansión, ya que buscamos conocer cómo se comportan los datos originales y no realizar estimaciones sobre la población argentina.

1. Cantidad de habitaciones del hogar (bhho02)

En el resumen inicial vimos que esta variable tenía un máximo de 92 habitaciones de uso exclusivo del hogar. Al revisar su distribución encontramos una mediana de 3 habitaciones y 143 registros por encima de 7, que es el límite superior calculado mediante el rango intercuartílico.

También la comparamos con bhcv02, que indica la cantidad total de habitaciones de la vivienda, y encontramos 50 registros donde el hogar declara tener más habitaciones de uso exclusivo que las que tiene la vivienda en total. Por ejemplo, el registro con 92 habitaciones exclusivas declara solamente 2 en toda la vivienda. Esto nos permitió identificar posibles inconsistencias que no se detectan solamente por la presencia de valores extremos, sino al comparar diferentes respuestas de la encuesta.

2. Ingresos mensuales del hogar (bhih01)

Elegimos esta variable porque encontramos una diferencia importante entre los ingresos habituales y los valores máximos.

La distribución presenta una mediana de $18.000 y una media de $22.446,65, mostrando una asimetría hacia los ingresos altos. Además, encontramos 9 registros que superan los $300.000 establecidos como máximo en el manual del INDEC, llegando hasta los $420.000. Otra cosa que observamos fue que el 93,04% de los ingresos positivos son múltiplos de $1.000 y el 51,08% son múltiplos de $5.000. Esto podría indicar que muchas personas informaron montos aproximados en lugar de cantidades exactas.

3. Minutos semanales caminando (biaf06_m)

Nos llamó la atención que esta variable alcanzara un máximo de 5.040 minutos semanales, equivalente a caminar 12 horas por día durante toda la semana.

Al revisar las 20.319 respuestas válidas encontramos una mediana de 180 minutos y una media de 327,64, mostrando una distribución asimétrica hacia los valores altos.

También vimos que 469 respuestas superan los 1.680 minutos semanales y solamente 30 superan los 3.360 minutos. Esto muestra que los tiempos extremadamente altos son poco frecuentes dentro de las respuestas válidas.

Aunque estos valores resultan llamativos, el máximo coincide con el documentado por el INDEC, por lo que no podemos considerarlos automáticamente incorrectos.

4. Cantidad de tragos declarados (bica05_03_b)

Seleccionamos esta variable porque en el resumen inicial encontramos valores considerablemente altos y una gran cantidad de datos nulos. De los 29.224 registros, solamente

1.364 tienen una respuesta válida. Esto se debe en parte a que la pregunta no corresponde a todos los encuestados, por lo que la cantidad de respuestas disponibles es mucho menor. Al analizar su distribución encontramos una mediana de 4,3 tragos y un máximo de 90. Además, 148 registros superan los 23,25 tragos, que es el límite superior calculado mediante el rango intercuartílico.

Esto muestra que la mayoría de las respuestas se concentra en cantidades relativamente bajas, pero existen algunos valores muy elevados que generan una distribución asimétrica.

5. Índice de masa corporal autorreportado (imc)

Esta variable nos llamó la atención porque, a diferencia de las anteriores, encontramos valores extremos tanto bajos como altos. Por eso decidimos revisar cómo se distribuyen y qué tan frecuentes son. De las 26.995 observaciones válidas obtuvimos una mediana de 26,53. Sin embargo, encontramos valores que van desde 10,38 hasta 66,67, con 14 registros inferiores a 15 y 61 superiores a 50.

Vimos que estos valores representan una proporción muy pequeña de las observaciones y que los extremos aparecen en ambos lados de la distribución. También hay que considerar que el IMC se calcula utilizando el peso y la talla declarados por los encuestados, y no las mediciones físicas del segundo paso. Por eso, aunque los valores extremos se encuentran dentro del rango documentado, no podemos determinar si son correctos sin revisar las medidas utilizadas para calcularlos.

Conclusiones de la exploración

Encontramos algunas inconsistencias concretas, como hogares que declaran más habitaciones exclusivas que habitaciones totales en la vivienda, e ingresos superiores al máximo documentado por el INDEC. En las otras variables encontramos valores extremos, pero no tenemos información suficiente para afirmar que sean errores.

También vimos que no todos los valores extremos representan errores y que es importante considerar el significado de cada variable antes de decidir si requieren algún tratamiento.

Limpieza y preparación de los datos

Después del análisis exploratorio seleccionamos 17 variables de las 287 originales, correspondientes a las que vamos a utilizar para nuestras hipótesis. En la sección 2.1 de la notebook realizamos este recorte y renombramos algunas columnas para facilitar su interpretación.

En la sección 2.2 analizamos los valores nulos y posibles outliers de las variables seleccionadas. Encontramos grandes diferencias en la cantidad de datos disponibles, principalmente por los distintos pasos de la encuesta. Por eso decidimos no eliminar todos los registros incompletos ni realizar imputaciones, ya que perderíamos información que podía ser útil para otros análisis.

Luego, en la sección 2.3 realizamos controles para detectar posibles inconsistencias, como identificadores duplicados, valores imposibles o diferencias entre el IMC registrado y el calculado. No encontramos problemas en estos controles, aunque identificamos algunos valores extremos que decidimos conservar porque no contamos con información suficiente para considerarlos errores.

Por último, construimos una muestra para cada hipótesis, eliminando únicamente los registros que no tenían la información necesaria para ese análisis y aplicando los filtros correspondientes. También verificamos que las muestras resultantes no tuvieran duplicados, valores faltantes en las variables requeridas ni factores de expansión no positivos.

Los criterios utilizados para limpiar los datos y construir las submuestras están detallados en las secciones 2.1, 2.2 y 2.3 de la notebook.

3. Hipótesis y resolución

3.1. Hipótesis 1: Perímetro de cintura en mujeres adultas

3.1.1. Definición de la hipótesis

El perímetro de cintura es un indicador de grasa abdominal, relacionado con el riesgo cardiovascular y metabólico. En mujeres adultas, un valor igual o superior a 88 cm se considera una referencia de riesgo elevado.

Queremos investigar si más de la mitad de las mujeres adultas alcanza o supera este umbral en la población urbana argentina.

Hipótesis: Más del 50% de las mujeres adultas presenta un perímetro de cintura igual o superior a 88 cm.

- H0: $p \leq 0{,}50$
- H1: $p > 0{,}50$

Donde p representa la proporción de mujeres que alcanzan o superan los 88 cm.

3.1.2. Estrategia de abordaje

Utilizamos la muestra de mediciones físicas del Paso 2, seleccionando únicamente mujeres con registros válidos del perímetro de cintura (sección 2.3.3 de la notebook).

Calculamos la proporción de mujeres que alcanzan o superan los 88 cm, tanto en la muestra como aplicando el factor de expansión wf2p para obtener una estimación poblacional.

Para evaluar la hipótesis realizamos un contraste unilateral de proporciones, utilizando los 200 pesos replicados bootstrap del INDEC para calcular el error estándar. Trabajamos con un nivel de significancia de 0,05 y calculamos también el intervalo de confianza del 95% y el coeficiente de variación para evaluar la precisión de la estimación.

El procedimiento y los gráficos se encuentran en la sección 4.1 de la notebook.

3.1.3. Resultados obtenidos y discusión

De las 9.388 mujeres analizadas, 4.943 presentan un perímetro de cintura igual o superior a 88 cm, equivalente al 52,65% de la muestra. Sin embargo, al aplicar los factores de expansión, esta proporción disminuye al 48,57%.

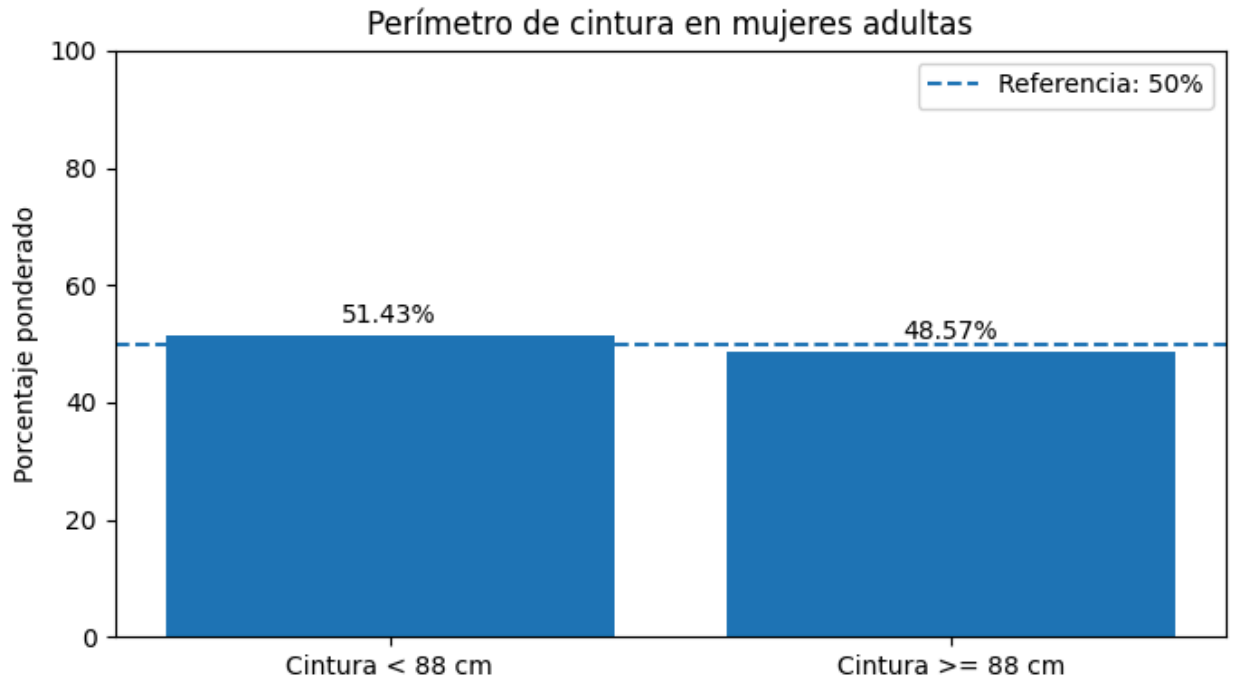


Figura 1. Porcentaje ponderado de mujeres según su perímetro de cintura, con referencia al 50%.

El intervalo de confianza del 95% fue de [46,44%; 50,70%], por lo que incluye el valor de referencia. El coeficiente de variación fue del 2,24%, indicando una buena precisión de la estimación.

La prueba obtuvo un p-valor de 0,9057, superior al nivel de significancia de 0,05. Por lo tanto, no rechazamos la hipótesis nula.

No encontramos evidencia suficiente para afirmar que más del 50% de las mujeres adultas tiene un perímetro de cintura igual o superior a 88 cm.

Sin aplicar los factores de expansión, la proporción supera el 50%, pero al utilizar wf2p disminuye al 48,57%. Esta diferencia cambia la interpretación inicial de los datos.

3.2. Hipótesis 2: Presión sistólica y actividad física

3.2.1. Definición de la hipótesis

La actividad física regular se relaciona con una mejor salud cardiovascular y con el control de la presión arterial. A partir de esto, queremos analizar si las personas con un nivel bajo de actividad física presentan una presión sistólica mayor que aquellas con un nivel alto.

Hipótesis: Las personas adultas con actividad física baja presentan una presión sistólica media mayor que aquellas con actividad física alta.

- H0: $\mu_{baja} \leq \mu_{alta}$
- H1: $\mu_{baja} > \mu_{alta}$

3.2.2. Estrategia de abordaje

Trabajamos con las mediciones físicas del Paso 2, seleccionando los registros con presión sistólica válida y niveles de actividad física alto o bajo (sección 2.3.3 de la notebook).

Comenzamos comparando las distribuciones de ambos grupos mediante un boxplot. Después calculamos sus medias ponderadas utilizando wf2p y realizamos un contraste unilateral de diferencia de medias.

Para calcular el error estándar utilizamos los 200 pesos replicados bootstrap del INDEC, con un nivel de significancia de 0,05.

Los cálculos y gráficos se encuentran en la sección 4.2 de la notebook.

3.2.3. Resultados obtenidos y discusión

Se analizaron 10.336 registros, de los cuales 2.718 corresponden a actividad física alta y 7.618 a actividad baja.

Las medias ponderadas fueron de 127,16 mmHg para el grupo de actividad alta y 131,49 mmHg para el de actividad baja.

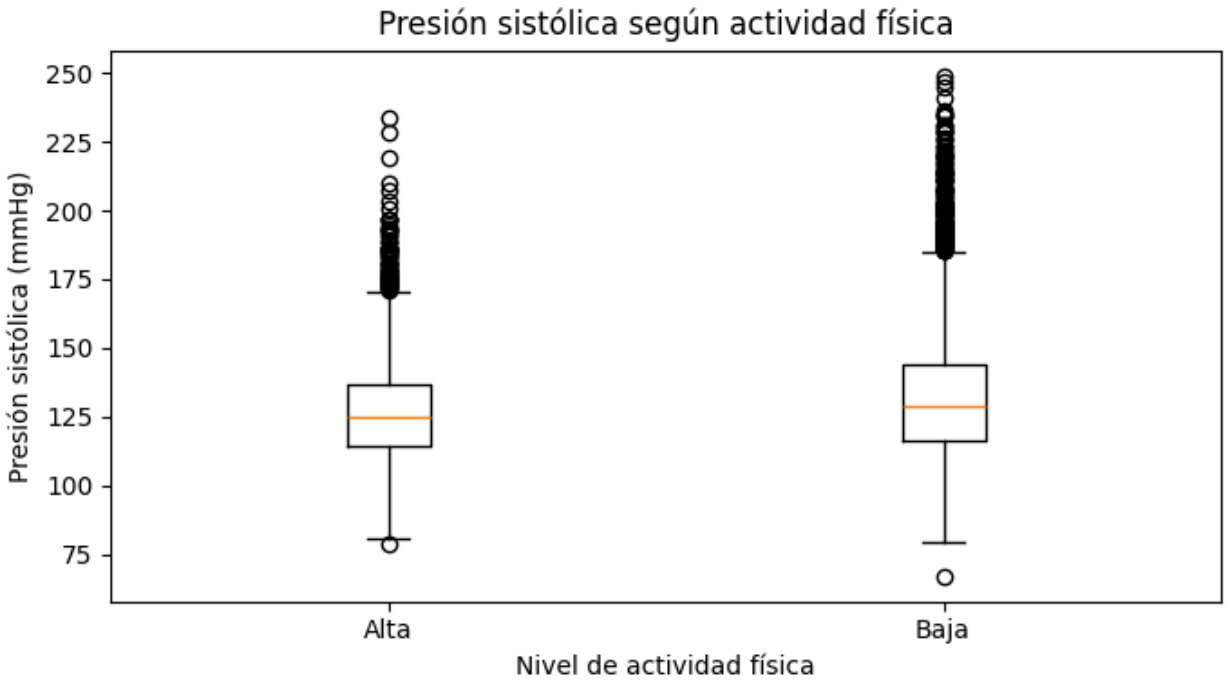


Figura 2. Distribución de la presión sistólica según el nivel de actividad física.



Figura 3. Medias ponderadas de presión sistólica e intervalos de confianza del 95%.

La diferencia estimada entre las medias fue de 4,32 mmHg, con un intervalo de confianza del 95% entre 2,83 y 5,81 mmHg.

El contraste obtuvo un p-valor de $6{,}69 \times 10^{-9}$, inferior a 0,05, por lo que rechazamos la hipótesis nula.

Los resultados respaldan nuestra hipótesis inicial de que las personas con actividad física baja presentan una presión sistólica media mayor que aquellas con actividad alta.

Sin embargo, esto no significa que la actividad física sea necesariamente la causa de la diferencia. También pueden intervenir otros factores, como la edad, que no estamos controlando en esta comparación.

3.3. Hipótesis 3: Consumo de frutas y verduras e IMC

3.3.1. Definición de la hipótesis

La alimentación es uno de los factores relacionados con el peso corporal. Un mayor consumo de frutas y verduras puede contribuir al control del peso, aunque también intervienen otros factores, como la edad y la actividad física.

En este caso queremos investigar si las personas que consumen más frutas y verduras presentan un IMC menor, incluso al considerar estas otras variables.

Hipótesis: Un mayor consumo diario de frutas y verduras se asocia con un menor IMC, después de considerar la edad y el nivel de actividad física.

- H0: $\beta_consumo \geq 0$
- H1: $\beta_consumo < 0$

3.3.2. Estrategia de abordaje

Utilizamos la muestra de mediciones físicas del Paso 2, seleccionando los registros válidos de IMC, consumo de frutas y verduras, edad y actividad física (sección 2.3.3 de la notebook).

Primero observamos la relación entre el consumo y el IMC mediante un gráfico de dispersión. Después aplicamos una regresión lineal múltiple ponderada, utilizando wf2p y los 200 pesos replicados bootstrap del INDEC para calcular los errores estándar.

Evaluamos el coeficiente del consumo mediante un contraste unilateral, con un nivel de significancia de 0,05. También revisamos los residuos para identificar posibles problemas en el ajuste.

Los procedimientos se encuentran en la sección 4.3 de la notebook.

3.3.3. Resultados obtenidos y discusión

Se analizaron 15.838 registros válidos, con un IMC promedio de 28,23 y un consumo medio de 2,03 porciones diarias de frutas y verduras.

El gráfico de dispersión no muestra una relación lineal negativa clara entre ambas variables. Además, en los residuos encontramos una dispersión considerable y algunos valores extremos.

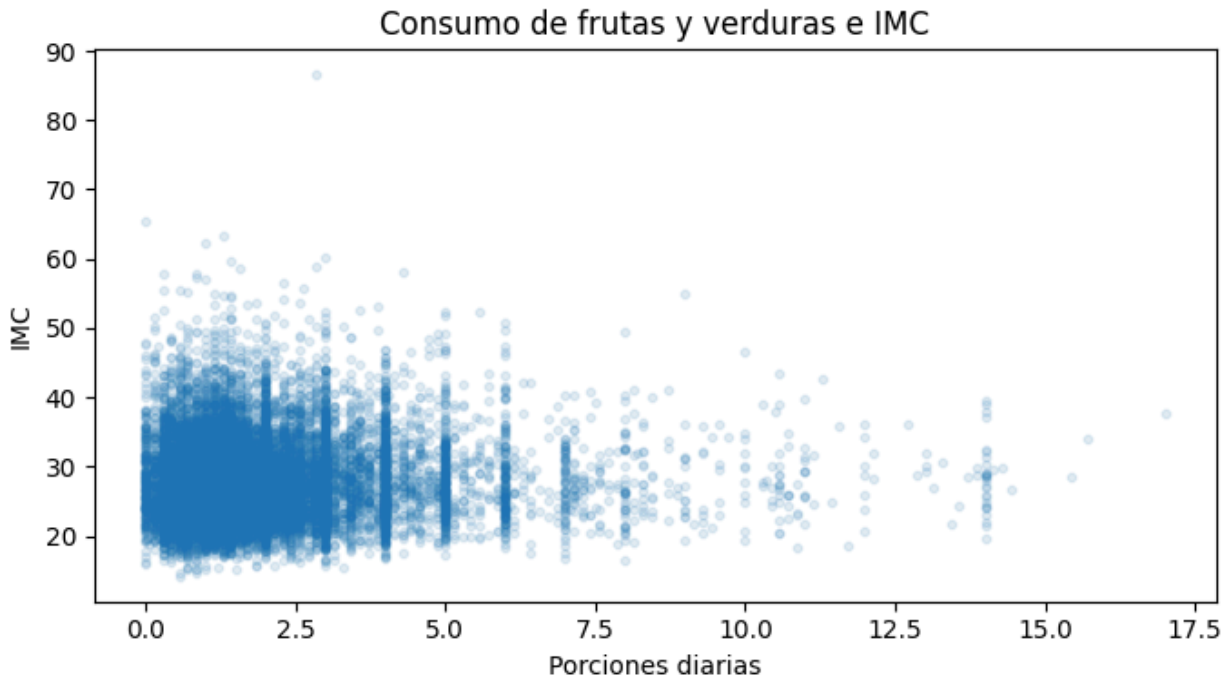


Figura 4. Relación entre el consumo diario de frutas y verduras y el IMC.

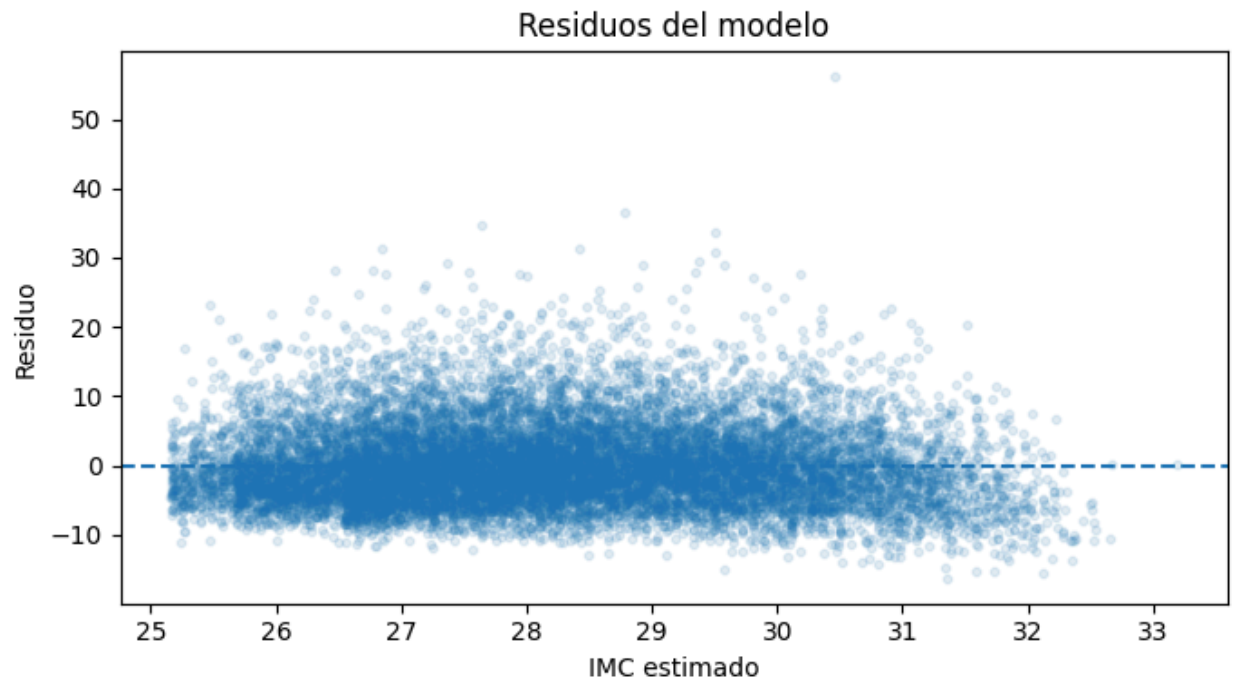


Figura 5. Distribución de los residuos del modelo de regresión.

El coeficiente del consumo fue de 0,01661, con un intervalo de confianza del 95% entre -0,07112 y 0,10435. Por otra parte, la edad y los niveles de actividad física mostraron asociaciones estadísticamente significativas con el IMC.

Para nuestra hipótesis obtuvimos un p-valor de 0,6447, superior a 0,05. Por lo tanto, no rechazamos la hipótesis nula.

No encontramos una relación significativa entre el consumo de frutas y verduras y el IMC al considerar la edad y la actividad física. De todas formas, estamos utilizando solamente el consumo de frutas y verduras, que no representa toda la alimentación de una persona.

3.4. Hipótesis 4: Consumo de frutas y verduras

3.4.1. Definición de la hipótesis

La OMS recomienda consumir al menos cinco porciones diarias de frutas y verduras para mantener una alimentación saludable y reducir el riesgo de enfermedades.

Queremos comprobar si el consumo promedio de la población adulta argentina se encuentra por debajo de esta recomendación.

Hipótesis: El consumo medio diario de frutas y verduras en la población adulta urbana argentina es inferior a cinco porciones.

- H0: $\mu \geq 5$
- H1: $\mu < 5$

3.4.2. Estrategia de abordaje

Utilizamos los registros válidos de consumo diario de frutas y verduras del Paso 1 de la encuesta (sección 2.3.3 de la notebook).

Analizamos su distribución y calculamos las medidas descriptivas. Luego aplicamos el factor de expansión wf1p para estimar la media poblacional y realizamos un contraste unilateral, utilizando los 200 pesos replicados bootstrap del INDEC para calcular el error estándar.

El nivel de significancia utilizado fue de 0,05. Los cálculos y gráficos se encuentran en la sección 4.4 de la notebook.

3.4.3. Resultados obtenidos y discusión

Se analizaron 28.471 registros válidos. El consumo promedio observado fue de 2,07 porciones diarias, mientras que la media ponderada fue de 2,03 porciones.

El gráfico muestra que la mayor parte de los consumos se concentra por debajo de las cinco porciones recomendadas. Además, estimamos que el 93,96% de la población estudiada no alcanza esa cantidad.

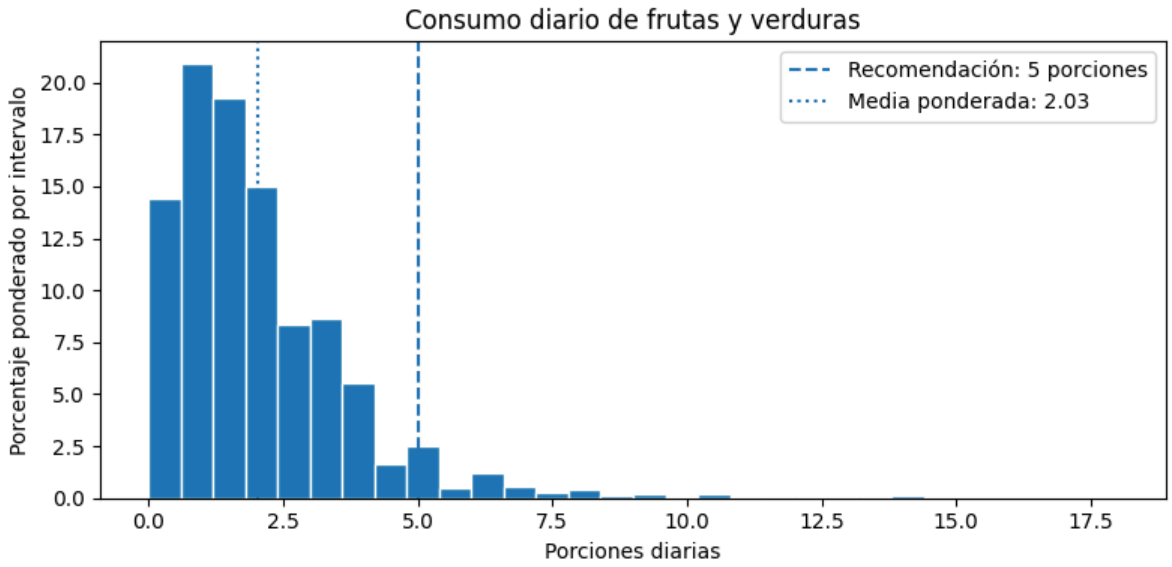


Figura 6. Distribución ponderada del consumo diario de frutas y verduras.

El intervalo de confianza del 95% fue de [1,9918; 2,0676], completamente por debajo de las cinco porciones. El coeficiente de variación fue del 0,95%, lo que indica una buena precisión de la estimación.

La prueba obtuvo un p-valor inferior, asi que rechazamos la hipótesis nula.

Encontramos evidencia estadística suficiente para afirmar que el consumo medio diario de frutas y verduras es inferior a las cinco porciones recomendadas por la OMS.

La diferencia es considerable: el promedio estimado es de apenas 2,03 porciones, menos de la mitad de la cantidad recomendada.

3.5. Hipótesis 5: IMC y actividad física

3.5.1. Definición de la hipótesis

La actividad física es uno de los factores relacionados con el peso corporal. En esta hipótesis buscamos determinar si el IMC presenta diferencias entre personas con distintos niveles de actividad física.

Hipótesis: El índice de masa corporal, calculado a partir de las mediciones físicas de peso y talla, cambia según el nivel de actividad física de las personas.

- H0: μ_alta = μ_media = μ_baja

- H1: Al menos una de las medias es diferente.

3.5.2. Estrategia de abordaje

Trabajamos con los registros válidos de IMC y actividad física del Paso 2, separando a las personas en tres grupos: actividad alta, media y baja (sección 2.3.3 de la notebook).

Comparamos sus distribuciones y medias, y luego realizamos un contraste global de igualdad de medias utilizando el factor de expansión wf2p. La variabilidad se calculó mediante los 200 pesos replicados bootstrap del INDEC.

También hicimos comparaciones exploratorias entre los grupos para identificar dónde se encontraban las diferencias. Estas comparaciones se utilizaron como complemento del contraste global, con un nivel de significancia de 0,05.

El análisis completo se encuentra en la sección 4.5 de la notebook.

3.5.3. Resultados obtenidos y discusión

Se analizaron 16.282 registros válidos. Las medias ponderadas del IMC fueron de 26,69 para actividad alta, 27,68 para actividad media y 28,81 para actividad baja.

Se observa que el IMC promedio aumenta a medida que disminuye el nivel de actividad física.

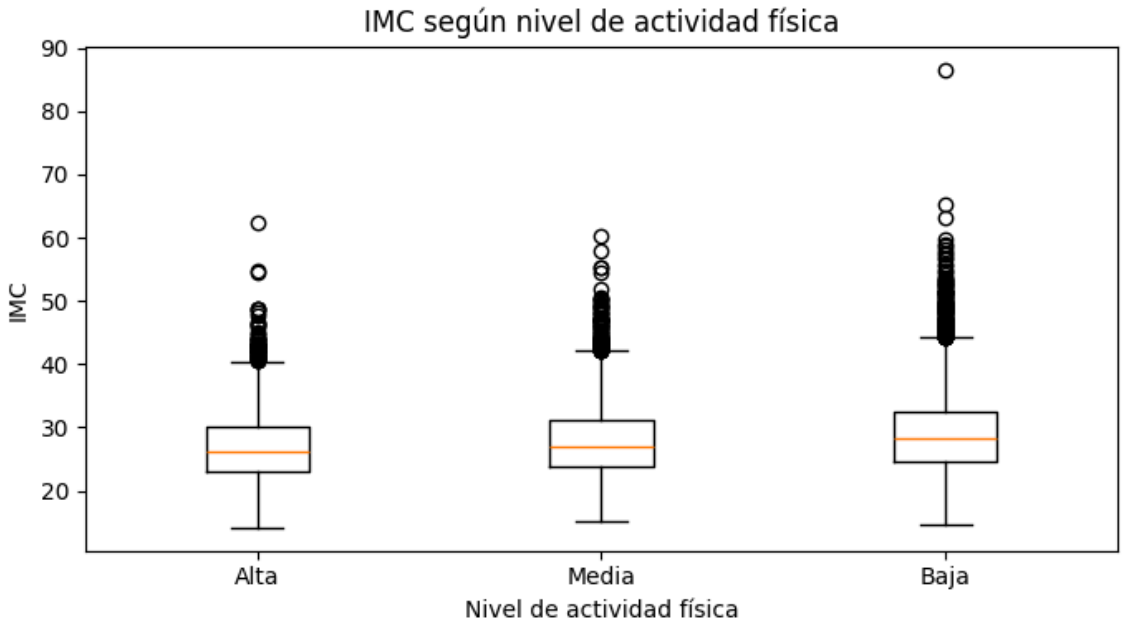


Figura 7. Distribución del IMC según el nivel de actividad física.

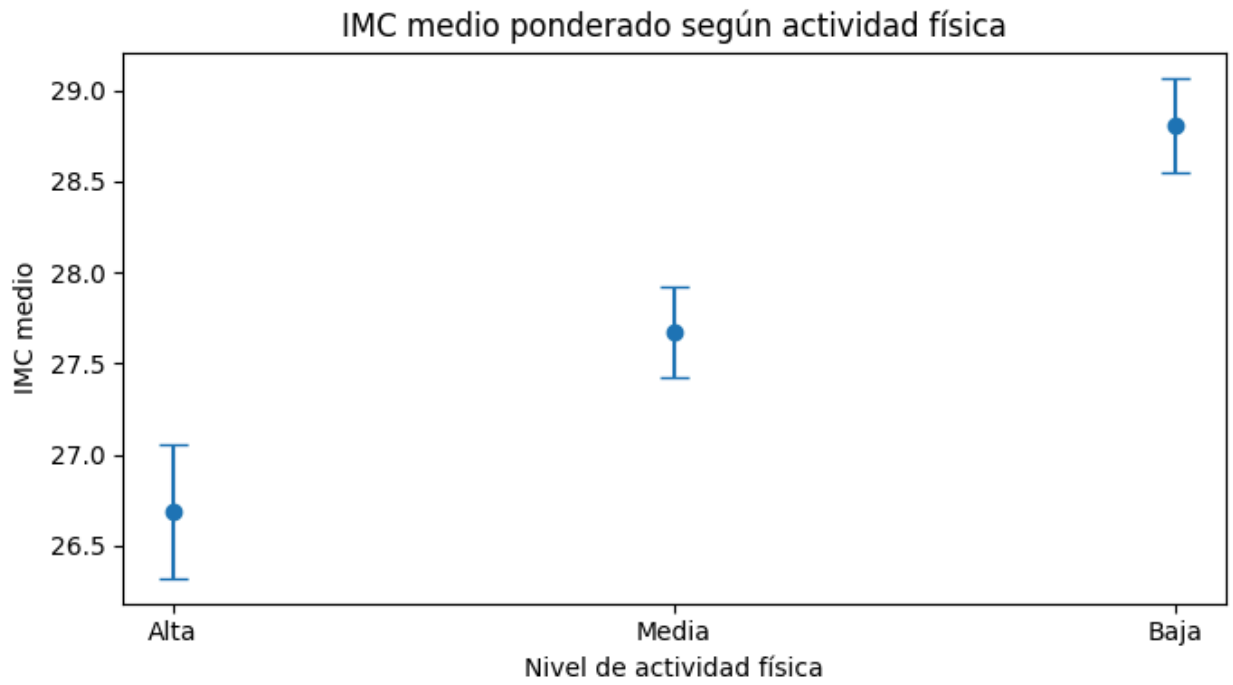


Figura 8. IMC medio ponderado e intervalos de confianza del 95% según actividad física.

El contraste global obtuvo un p-valor de $1{,}65 \times 10^{-22}$, inferior a 0,05. Por lo tanto, rechazamos la hipótesis nula y encontramos evidencia de que no todos los grupos tienen el mismo IMC medio.

Las comparaciones exploratorias también mostraron diferencias entre los tres niveles de actividad. La mayor se encontró entre actividad alta y baja, con 2,12 puntos de IMC.

Estos resultados respaldan la existencia de una asociación entre el IMC y la actividad física, con mayores valores promedio en las personas menos activas.

De todas formas, no podemos afirmar que las diferencias sean causadas únicamente por la actividad física, ya que también pueden intervenir otras características, como la edad y la alimentación.

3.6. Hipótesis 6: Relación entre glucemia, IMC, presión sistólica, cintura y edad

3.6.1. Definición de la hipótesis

La glucemia puede estar relacionada con diferentes características físicas y metabólicas, como la edad, el peso corporal y la presión arterial.

En esta última hipótesis queremos investigar si existe una relación lineal conjunta entre estas variables y la glucemia capilar en ayunas.

Hipótesis: Existe una relación lineal entre la glucemia capilar en ayunas, el IMC, la presión sistólica, el perímetro de cintura y la edad.

- H0: $\beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$
- H1: Al menos uno de los coeficientes es diferente de cero.

3.6.2. Estrategia de abordaje

Utilizamos los registros válidos de las mediciones bioquímicas del Paso 3, junto con las variables físicas y la edad (sección 2.3.3 de la notebook).

Aplicamos una regresión lineal múltiple ponderada, tomando la glucemia como variable dependiente y utilizando wf3p como factor de expansión. Los errores estándar se calcularon mediante los 200 pesos replicados bootstrap del INDEC.

Para evaluar la relación conjunta realizamos un contraste de Wald con un nivel de significancia de 0,05. También revisamos el R^2, la multicolinealidad y la distribución de los residuos para conocer las limitaciones del modelo.

Los cálculos y gráficos se encuentran en la sección 4.6 de la notebook.

3.6.3. Resultados obtenidos y discusión

Se analizaron 5.039 registros válidos. Dentro del modelo, la edad y el perímetro de cintura presentaron asociaciones positivas y estadísticamente significativas con la glucemia. En cambio, el IMC y la presión sistólica no mostraron asociaciones individuales significativas.

El R^2 ponderado fue de 0,0627, lo que indica que el modelo explica solamente el 6,27% de la variabilidad de la glucemia. No encontramos problemas graves de multicolinealidad, aunque los gráficos de residuos muestran valores extremos y desviaciones importantes de la normalidad.

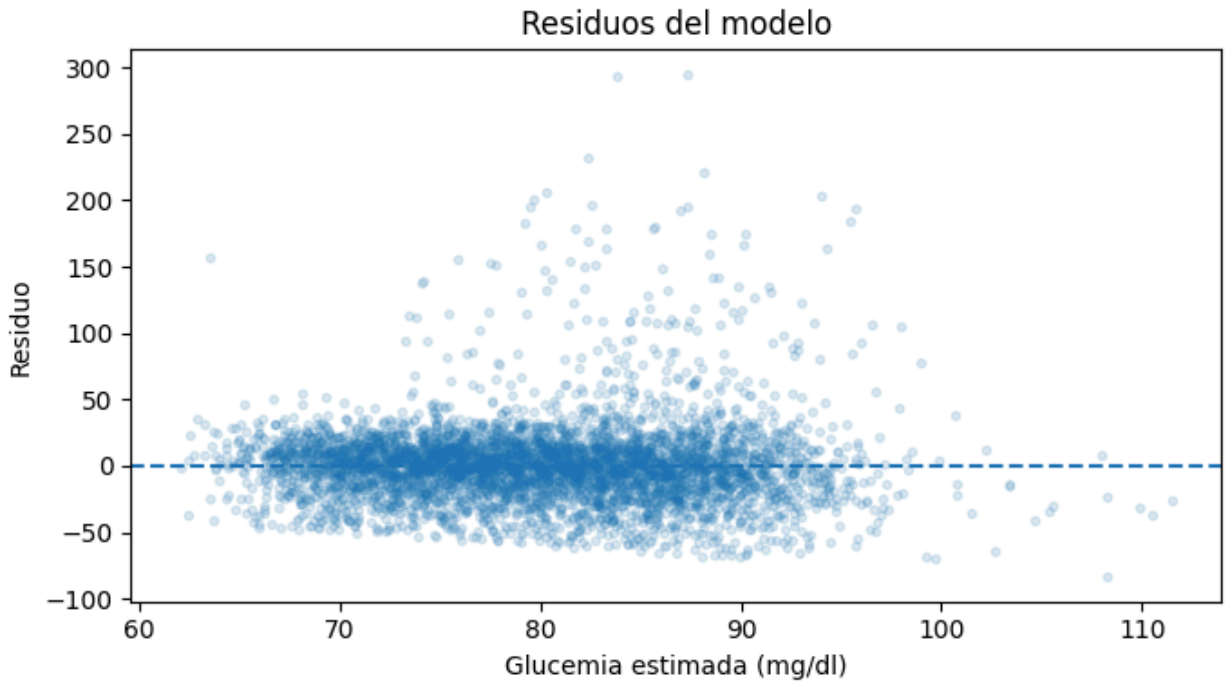


Figura 9. Distribución de los residuos del modelo de regresión.

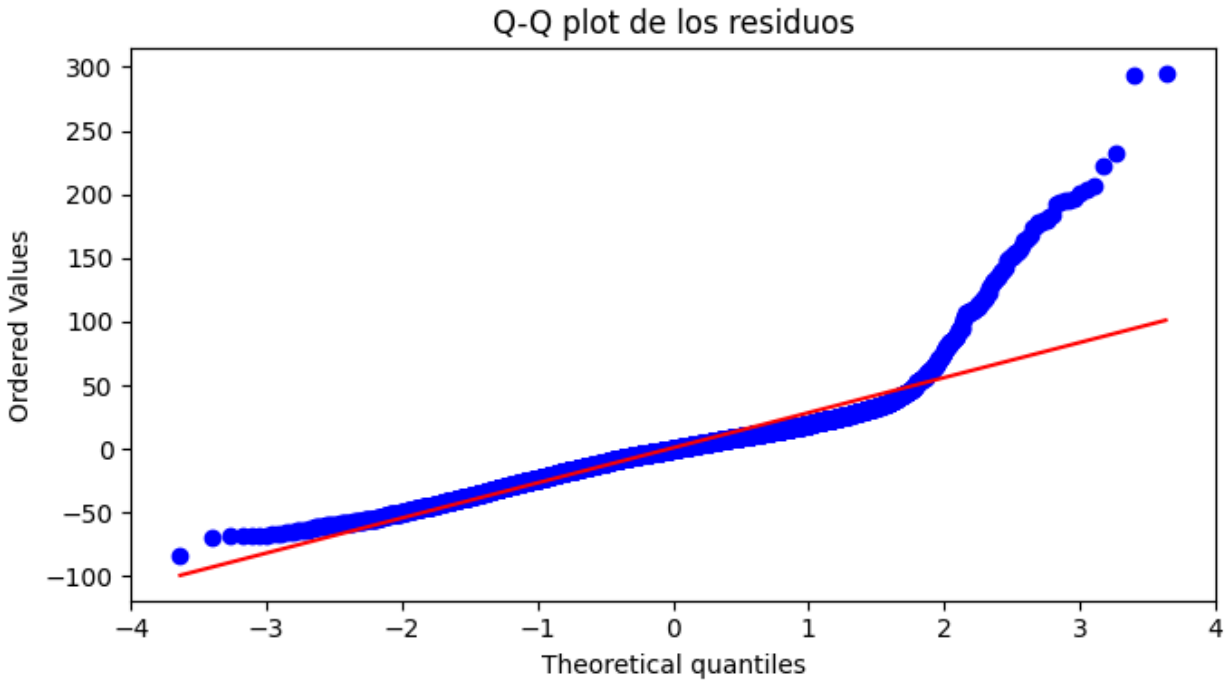


Figura 10. Gráfico Q-Q de los residuos.

El contraste global obtuvo un p-valor de $7{,}13 \times 10^{-30}$, inferior a 0,05, por lo que rechazamos la hipótesis nula.

Esto indica que al menos una de las variables explicativas presenta una asociación estadísticamente significativa con la glucemia dentro del modelo planteado. Sin embargo, no significa que el modelo lineal describa correctamente toda la relación entre estas variables.

Aunque el contraste global resultó significativo, el modelo explica solamente el 6,27% de la variabilidad de la glucemia. Además, encontramos valores extremos y desviaciones importantes de la normalidad en los residuos. Estos problemas limitan la utilidad del modelo para explicar la glucemia.

4. Conclusiones

A partir de los resultados obtenidos encontramos algunas relaciones interesantes entre los factores de riesgo estudiados. Las personas con menor actividad física presentaron mayores valores promedio de IMC y presión sistólica, mientras que el consumo diario de frutas y verduras resultó considerablemente inferior a las cinco porciones recomendadas. Estos resultados van en línea con algunos de los problemas de salud que se mencionan en el informe oficial del INDEC, principalmente los relacionados con la alimentación, el exceso de peso y la actividad física.

Sin embargo, no todas las relaciones que planteamos pudieron respaldarse estadísticamente. Además, hay que considerar que las asociaciones encontradas no permiten establecer relaciones de causa y efecto, ya que pueden intervenir otras variables que no incluimos en los análisis. También encontramos limitaciones en algunos modelos, como el de glucemia, que resultó estadísticamente significativo pero explicó una proporción muy pequeña de la variabilidad de los datos.

En general, encontramos diferencias en el IMC y la presión sistólica según el nivel de actividad física, pero no pudimos demostrar una relación negativa entre el consumo de frutas y verduras y el IMC. También vimos que obtener un resultado estadísticamente significativo no significa necesariamente que el modelo explique bien los datos, como ocurrió con la glucemia.

Referencias

[1] Instituto Nacional de Estadística y Censos (INDEC). (2019). 4° Encuesta Nacional de Factores de Riesgo, Resultados definitivo. [En líneas] Disponible:

[2] Instituto Nacional de Estadística y Censos (INDEC). (2019). 4° Encuesta Nacional de Factores de Riesgo, Manual de Uso de la Base de Datos. [En líneas] Disponible: https://www.indec.gob.ar/ftp/cuadros/menusuperior/enfr/manual_base_usuario_enfr2018.pdf.

[3] Instituto Nacional de Estadística y Censos (INDEC). (2019). 4° Encuesta Nacional de Factores de Riesgo, Factores de expansión, estimación y cálculo de los errores de muestreo. [En líneas] Disponible: https://www.indec.gob.ar/ftp/cuadros/menusuperior/enfr/nota_tecnica_enfr_2018.pdf